Knowly 챗봇 검색 품질 진단 보고서

1~3차 테스트 결과 · 실패 원인 분석 · 검색 정확도 개선 방안

대상: Knowly 사내 업무 도우미(cheonax.duckdns.org) / 문서: 가상 QA팀 문서(업로드본 01_QA~10_QA) / 문항: 5개 주제 × 5개 표현 = 25문항 / 시행: 2026-11-05 ~ 11-06, 문항마다 새 대화로 1회 질의 / 운영 예정 모델: qwen/qwen3-14b

1. 회차별 테스트 조건과 결과

회차	답변 모델	검색 설정 (키워드 최소 / 의미 최소 / 의미 비중)	대상	정답	주요 실패 형태
1차	qwen/qwen3-14b	0.35 / 0.55 / 0.60	25문항	**9 (36%)**	원문 조각만 노출(폴백) 16건
2차	openai/gpt-6-luna	0.35 / 0.55 / 0.60	25문항	**14 (56%)**	답변 유보 8, 폴백 2, 오답 1
3차	openai/gpt-6-luna	0.20 / 0.55 / 0.75 (테스트 중 변경 확인)	실패 16문항	**8 / 16**	답변 유보 7, 폴백 1

3차는 1차 실패 16문항만 재실행했다. 1·2차에서 모두 정답이었던 9문항이 유지된다고 가정하면 25문항 기준 약 17건(68%)이다. 3차 테스트 도중 검색 설정이 바뀐 것이 확인되어, 3차 개선분에는 설정 변경 효과가 섞여 있다.

정답률 (25문항 기준)	3차 남은 실패	그중 검색 단계 원인	그중 생성 단계 원인
36% → 68%	**8건**	**5~6건**	**2건**
1차 Qwen → 3차 Luna + 설정 변경 (추정)	유보 7 · 시간 초과 폴백 1	정답 조각이 근거에 못 들어감	근거는 있으나 답 실패

2. 핵심 결론

① **1차(Qwen)의 대량 실패는 주로 답변 생성 단계 문제였다.** 같은 검색 결과로 Luna는 5문항을 바로 맞혔다. Qwen이 문서를 찾고도 답을 완성하지 못한 것으로, 형식 오류나 시간 초과가 원인으로 추정된다.

② **지금 남은 실패는 대부분 검색 단계 문제다.** 검색 미리보기로 보니, 실패 문항은 정답 조각이 기준점에 0.01~0.06 모자라 빠졌거나 후보에 아예 없었다. 업무 관용어·구어체 질문에서 특히 두드러진다.

③ **의미 검색 점수가 변별력이 낮아 결과가 불안정하다.** 관련 있는 조각과 없는 조각이 모두 0.55~0.65에 몰려 있다. 설정을 조금만 바꿔도 결과가 크게 달라지고(3차 Q01-3·Q01-5 개선), 같은 질문도 회차마다 답이 바뀐다(Q01-2: 근거만 → 오답 → 정답).

결론: 모델을 Qwen으로 유지하려면 ① Qwen 답변 생성 경로의 안정화와 ② 검색 단계 개선(용어 정규화, 재순위화, 문서·청킹 정리)을 함께 진행해야 한다. 검색 단계 개선은 모델과 무관하게 효과가 난다.

실패 16문항 회차별 추적과 검색 진단

결과: 정답 / 근거만=원문 조각만 노출(폴백) / 무관=다른 문서 제시 / 유보="등록된 답변 없음" / 오답. 검색 미리보기: 관리자 설정의 미리보기 기능으로 근거 후보 8개와 키워드·의미 점수를 확인(★ = 정답 조각).

문항	표현	1차 Qwen	2차 Luna	3차 Luna	검색 미리보기 결과	3차 실패 단계
Q01-1	규정 용어	근거만	정답	정답	★ 1·2위 (의미 0.73/0.71)	—
Q01-2	판단 요구	근거만	오답	정답	★ 1·2위, 구버전 기준(2시간) 조각도 7위로 함께 사용	— (구버전 충돌로 재발 위험)
Q01-3	신입 배경	무관	유보	정답	★ 3위. 1·2위는 IT 온보딩·라이선스 문서("입사" 키워드)	—
Q01-5	관용어	무관	유보	정답	★ 2·5위. 1위 IT 온보딩("장애" 키워드 0.62)	—
Q02-1	규정 용어	근거만	정답	정답	★ 7위 (1위는 같은 문서 다른 조항, 키워드 0.93)	—
Q02-2	판단 요구	근거만	근거만	근거만	유사 조항(운영 규정 핫픽스 절차) 3·6위, 6장 게이트 조항 불명확	생성 매번 약 21~25초 후 폴백
Q02-3	신입 배경	무관	유보	유보	★ 3위 포함 (전 후보 의미 0.56~0.62로 차이 없음)	생성 근거 있는데 유보
Q02-5	관용어	무관	무관	유보	★ 없음. 긴급 예외·4시간 조각만, 의미 0.61~0.63 일렬	검색 어휘 불일치
Q03-1	규정 용어	근거만	정답	정답	★ 1위	—
Q03-5	관용어	근거만	유보	유보	★ 3개 후보에 있었으나 전부 제외 (키워드 0.09~0.18, 의미 0.49~0.53)	검색 임계값 컷
Q04-4	숫자·표	근거만	정답	정답	★ 6위 (1차는 표가 행 중간에서 잘려 노출)	—
Q04-5	관용어	무관	유보	유보	★ 없음. 근거 1개만 통과(장애 보고서 표지, 의미 0.44)	검색 어휘 불일치
Q05-2	판단 요구	근거만	유보	유보	장애 보고서 조각 다수 포함, 정답 문장 포함 여부는 미리보기 화면에서 확인 불가	미확정 (검색 또는 생성)
Q05-3	신입 배경	근거만	정답	정답	미리보기는 근거 0개였으나 실제 채팅은 정답 (미리보기·채팅 경로 차이 추정)	—
Q05-4	숫자·표	근거만	유보	유보	★ 없음. 타임라인 표 미포함, IT 배포 가이드 혼입	검색 표 청킹
Q05-5	관용어	무관	유보	유보	★ 의미 0.54로 기준 0.55에 0.01 미달해 제외	검색 임계값 컷

검색 진단 요약 (미리보기 확인 가능 15문항)	건수	의미
정답 조각이 근거 8개 안에 포함	10 / 15	이 중 3차 정답 7건, 실패 3건(생성 단계 2건 포함)
정답 조각이 상위 3위 안에 포함	7 / 15	모델이 실제로 읽는 조각 수가 적다면 6~7위 정답은 놓칠 수 있음
정답 조각이 후보에 있었으나 기준 미달로 제외	3 / 15	Q03-5, Q05-5, Q05-3(미리보기 기준)
정답 조각이 후보 8개에 없음	3 / 15	Q02-5, Q04-5, Q05-4 (관용어·표)

미리보기 결과는 테스트 당시 설정 기준이다. ★ 판정은 화면에 표시된 조각 일부로 했으므로 조각이 잘린 경우 누락될 수 있다.

왜 이런 문제가 발생했나 (원인 분석)

3. 답변이 만들어지는 경로와 문제 위치

① 문서 등록
구버전 원고·파일명 어긋남·카테고리 "기타"

→

② 청킹(조각 나누기)
표 행 분할, 표지·머리글 조각, 절 제목 어긋남

→

③ 검색
어휘 불일치, 키워드 잡음, 의미 점수 압축, 고정 기준선

→

④ 답변 생성
Qwen 형식 오류·시간 초과, 과도한 유보

빨간 테두리는 이번 테스트에서 문제가 확인된 단계. 한 단계의 오류가 뒤 단계로 그대로 전달된다.

4. 원인별 근거와 영향

#	원인	관찰된 근거	영향 문항
C1	**질문과 문서의 어휘 불일치**	"긴급 패치", "OK 사인", "새어 나간 버그", "서비스 터지는"은 문서의 "핫픽스", "최종 승인", "결함 유출률", "S1"과 단어가 겹치지 않는다. 대신 "장애", "입사", "배포"가 겹치는 IT·인사 문서가 상위에 올라왔다.	Q01-3, Q01-5, Q02-5, Q03-5, Q04-5, Q05-5 (관용어 5문항은 1·2차 모두 0/5)
C2	**의미 검색 점수의 변별력 부족**	정답·오답 조각 모두 의미 점수 0.55~0.65 구간에 몰림. 정답 조각이 같은 문서의 다른 조항에 밀려 6~7위로 내려감. 현재 임베딩 모델이 한국어 업무 문장을 충분히 구분하지 못하는 것으로 보인다.	Q02-1(7위), Q04-4(6위), Q02-3, 회차 간 결과 흔들림
C3	**고정 점수 기준선에 의한 컷**	"의미 0.55 이상 또는 키워드 기준 이상"만 근거로 쓰는 방식. 점수가 압축된 상태에서는 0.01 차이로 정답이 빠진다(Q05-5: 0.54). 기준선을 바꾸자 3차에서 결과가 바로 달라졌다.	Q03-5, Q05-5
C4	**키워드 추출 잡음**	"등록하고" → "등록, 록하, 하고", "시작했으면" → "작했, 했으, 으면"처럼 의미 없는 두 글자 조각까지 검색어로 쓴다. 질문이 길고 구어체일수록 일치 비율이 낮아진다(규정 용어 질문 0.69 vs 판단형 질문 0.29~0.46).	구어체·판단형 전반
C5	**청킹(조각 나누기) 구조**	표가 행 중간에서 잘림(1차 Q04-4: 98%·10건 행 누락), 장애 타임라인 표 미검색(Q05-4). 문서 표지·머리글 조각이 검색됨(Q02-3, Q04-5). 조각에 붙은 절 제목과 실제 본문이 한 칸씩 어긋남(예: "5. 완료 시…" 제목 아래 1~4단계 내용).	Q04-4, Q05-4, Q02-3, Q04-5
C6	**문서 데이터 품질**	수정 전 구버전이 등록되어, 같은 기준이 문서마다 다르게 남아 있음(S1 2시간 vs 1시간) → 2차 오답. 04번 문서 누락으로 파일명과 내용이 어긋남. QA 문서가 모두 "기타"로 분류되어 부서 필터를 쓸 수 없음.	Q01-2, 출처 표기 혼란
C7	**답변 생성 단계**	Qwen은 1차에서 16건이 폴백됐는데, 같은 검색 결과로 Luna는 5건을 바로 맞힘. qwen3-14b는 기본으로 사고 과정을 출력하는 모델이라, 응답이 길어져 시간 초과가 나거나 정해진 형식이 깨졌을 가능성이 높다(로그 확인 필요). Luna에서도 특정 질문(Q02-2)은 매번 21~25초 뒤 폴백됐고, 근거가 있는데도 유보한 경우(Q02-3)가 있다.	1차 16건, Q02-2, Q02-3
C8	**측정 조건의 불안정**	각 문항 1회 실행, 테스트 중 설정 변경, 미리보기와 실제 채팅 결과 불일치(Q05-3). 개선 효과를 정확히 판단하려면 조건 고정과 반복 측정이 필요하다.	전체 해석

검색 정확도를 높이려면 (개선 방안)

5. 단계별 개선 로드맵

단계	조치	원인	방법	기대 효과 / 확인 문항
즉시 설정·데이터만	문서 정리: 최신본 교체, 문서번호 이름, 04번 추가, QA 카테고리	C6	관리자 문서 관리에서 재등록. 문서명 예: "QA-PRC-005 결함 관리 프로세스"	구버전 충돌 오답 제거 (Q01-2), 출처 표기 정상화
	점수 기준선을 미리보기로 맞추기	C3	25문항을 미리보기로 돌려 정답 조각이 근거에 들어오는 비율을 기준선별로 비교. 시작점: 의미 최소 0.50, 키워드 최소 0.20, 의미 비중 0.75	Q03-5, Q05-5 회복. 단, 무관 조각 증가 여부를 함께 확인
	자주 묻는 관용어 질문을 FAQ로 등록	C1	관리자 "미등록 질문"에 쌓인 질문을 묶어 FAQ로 등록 (FAQ가 문서 검색보다 먼저 응답됨)	관용어 문항 즉시 대응, 등록 FAQ 현재 0건
	Qwen 사고 모드 끄기	C7	요청에 사고 모드 비활성 옵션 지정. 어렵다면 출력에서 사고 과정 부분을 지운 뒤 해석	Qwen 폴백 감소, 응답 시간 단축
단기 파이프라인 소규모 수정	질문 바꿔 쓰기(질의 재작성)	C1, C4	검색 전에 Qwen에게 질문을 규정 용어로 바꾸고 핵심 검색어를 뽑게 함. 예: "OK 사인 누가 줘?" → "출시 최종 승인권자"	관용어·구어체 5~6문항 (Q02-5, Q04-5 등)
	업무 용어 동의어 사전	C1	긴급 패치=핫픽스, 새어 나간 버그=결함 유출, 서비스 터짐=S1·서비스 중단, OK 사인=최종 승인 등을 검색어 확장에 사용	질의 재작성보다 단순하고 결과가 예측 가능
	한국어 형태소 분석기로 키워드 추출	C4	Kiwi·Mecab 등으로 명사·동사 원형만 추출해 키워드 검색(BM25)에 사용, 두 글자 조각·조사 제거	구어체·판단형 질문의 키워드 점수 정상화
	청킹 개선	C5	표지·머리글·바닥글 제거, 표는 행 단위로 나누고 각 행에 표 머리글 반복, 절 제목과 본문 정렬, 조각마다 문서번호·절 제목을 앞에 붙임	Q05-4(타임라인), Q04-4 안정화, 표지 노이즈 제거
	문서 메타데이터 활용	C6	문서번호·버전·시행일·카테고리를 조각에 저장. 같은 기준이 여러 조각에 있으면 시행일 최신 우선	개정 전후 기준 충돌 시 최신 기준으로 답변
중기 구성 요소 교체	재순위화 모델(reranker) 도입	C2, C3	후보 20~30개를 넓게 뽑은 뒤 reranker(예: bge-reranker-v2-m3)로 다시 점수 매겨 상위 5개만 사용. 고정 기준선 의존도를 낮춤	6~7위 정답 조각을 상위로 (Q02-1, Q04-4), 순위 안정화
	한국어에 강한 임베딩 모델로 교체	C2	bge-m3, multilingual-e5-large 등 다국어·한국어 성능이 검증된 모델로 바꾸고 전체 재색인	의미 점수 변별력 확대 (현재 0.55~0.65 압축 해소)
	Qwen 생성 경로 안정화	C7	답변 형식 단순화(결론·근거 위주), 약간 틀린 형식도 복구해 읽기, 입력 조각 3~5개, 시간 제한 조정, 근거가 있으면 부분 답변 허용	1차 폴백 16건 해소, 과도한 유보(Q02-3) 감소

6. 효과 측정 방법과 목표

지표	현재 (추정)	목표	측정 방법
정답 조각 포함률 (상위 5개 기준)	실패 문항 기준 47% (7/15)	90% 이상	검색 미리보기로 25문항 + 평가 질문 140문항 확인
직접 정답률	Luna 약 68%, Qwen 36%	Qwen 80% 이상	같은 25문항, 각 3회 반복 평균
오답률	4% (Luna 2차)	0%	버전 충돌 문항(Q01-2 등) 집중 확인
답변 유보율 (문서에 답이 있는 질문)	28% (3차, 7/25 추정)	10% 이하	문서에 없는 질문은 별도로 유보가 맞는지 확인

진행 원칙: ① 한 번에 하나만 바꾸고 25문항으로 재측정 ② 모델은 운영 모델(Qwen)로 고정 ③ 각 문항 3회 반복 ④ 검색 결과(조각·점수)와 최종 답변을 함께 기록해 실패 단계를 구분.

권장 순서: 문서 정리 → Qwen 사고 모드 끄기 → 기준선 조정 → 동의어·질의 재작성 → 청킹 개선 → reranker·임베딩 교체. 앞의 세 가지는 코드 수정 없이 오늘 바로 시작할 수 있다.

본 자료는 화면에 표시된 출력과 관리자 검색 미리보기에 근거한 분석이며, 내부 원인(특히 Qwen 폴백 사유)은 서버 로그로 확정해야 한다. 각 문항 1회 실행 결과이므로 소수 문항 차이는 변동 범위일 수 있다.